

# Previsão de Vendas Diárias de Propostas de Crédito: do AutoML à Econometria Interpretável

Construção da base, seleção experimental de modelos (TPOT  $\rightarrow$  *walk-forward*) e  
modelagem SARIMA com análise de intervenção de Box–Tiao

Daniel Ramazzotte

Disciplina: Econometria e Análise de Intervenção

Julho de 2026

## Resumo

Este trabalho aplica a metodologia clássica de Box–Jenkins, estendida pela análise de intervenção de Box–Tiao e por testes de cointegração, à previsão diária de duas séries operacionais de uma financeira de crédito: o *valor* monetário e a *quantidade* de propostas processadas por dia útil. O objetivo é testar se um modelo *branco* (interpretável) do tipo SARIMA, com uma *única especificação congelada*, consegue igualar ou superar o sistema de *AutoML* (TPOT) atualmente em produção, que é retreinado quase diariamente. As séries são identificadas como  $I(1)$  com sazonalidade semanal de dias úteis ( $s = 5$ ); os dias atípicos (incidentes operacionais e vésperas de feriado) são tratados por funções de transferência de intervenção em vez de descartados da estimação. A validação usa *walk-forward* de um passo à frente, sem vazamento, e o critério de seleção é o RMSPE — justificado por decompor o erro em viés e dispersão. Os principais resultados: (i) **não há cointegração** confiável entre valor e quantidade, legitimando a modelagem separada; (ii) a intervenção **descontamina o ajuste** — o teste de Ljung–Box deixa de rejeitar a hipótese de resíduos não-autocorrelacionados ( $p$  de  $\approx 0,01$  para 0,37 e 0,63); e (iii) o SARIMA **igualava ou supera** a pipeline em produção no RMSPE nas duas séries, preservando interpretabilidade estatística de cada componente.

**Palavras-chave:** SARIMA; análise de intervenção; Box–Tiao; cointegração; RMSPE; *walk-forward*; previsão de vendas.

## 1 Introdução

A área de crédito precisa antecipar, todo dia útil, duas grandezas operacionais distintas para o dia seguinte. A **quantidade** de propostas dimensiona a equipe e a fila de análise (capacidade de atendimento); o **valor** monetário dimensiona capital, caixa e risco. Ambas já são previstas em produção por um pipeline de *AutoML* (TPOT) — uma busca automatizada entre milhares de combinações de *features* e algoritmos de *machine learning*, *retreinado quase diariamente*. O pipeline é acurado, mas é uma **caixa-preta**: dele não se lê “quanto a fila pesa” nem “quanto um erro operacional custa” na previsão, e o retreino diário o torna caro e difícil de auditar.

**O estudo em três atos.** Este trabalho percorre a evolução completa do sistema de previsão:

1. **O baseline em produção** (Seção 3): a rotina diária de *AutoML* (TPOT), sua construção de base e engenharia de *features* por defasagens, e seus limites (caixa-preta, retreino diário).
2. **A seleção experimental** (Seção 4): um experimento controlado que compara dezenas de candidatos (modelos simples, *ensembles*, *deep learning* e séries temporais clássicas) sob *walk-forward* alinhado ao histórico, com o objetivo de *substituir o TPOT por um modelo fixo, rápido e confiável*.
3. **A modelagem econométrica** (Seções 5 em diante): o vencedor interpretável — um **SARIMA com análise de intervenção de Box–Tiao** — é então identificado, diagnosticado e estimado em detalhe.

**Pergunta de pesquisa.** Um modelo econométrico *clássico* de séries temporais (SARIMA), com estrutura interpretável e uma *única* especificação fixa (não retreinada a cada dia, apenas reestimada), consegue *igualar ou superar* a pipeline TPOT em produção nas duas séries que ela já prevê? Se o modelo branco vencer ou empatar, ganha-se interpretabilidade sem sacrificar acurácia: coeficientes com significância estatística, tratamento transparente dos dias atípicos (intervenção de Box–Tiao em vez de descarte cego) e um modelo auditável.


## 2 Dados e construção da base

As propostas (etapa 16) são agregadas em frequência **diária**, apenas em **dias úteis** (excluindo sábados, domingos e feriados nacionais via `workdays`). A ausência de feriados na grade produz uma sazonalidade semanal regular de período  $s = 5$ . A Tabela 1 resume as duas séries-alvo.

**Tabela 1:** Definição das séries-alvo. As duas têm o mesmo *status*: cada uma recebe seleção de ordem, intervenção, *ranking* e modelo recomendado próprios.

|                            | Valor (R\$)                                                    | Quantidade                        |
|----------------------------|----------------------------------------------------------------|-----------------------------------|
| Definição                  | valor monetário processado no dia                              | nº de propostas analisadas no dia |
| Papel                      | série-alvo                                                     | série-alvo                        |
| Histórico                  | $\approx 410$ dias úteis (07/11/2024 $\rightarrow$ 01/07/2026) |                                   |
| Janela <i>walk-forward</i> | $N = 209$                                                      | $N = 211$                         |

Ambas exibem **nível que passeia** (não-estacionariedade), **sazonalidade semanal** e **quebras pontuais** nos dias de erro operacional (Figura 1).



**Figura 1:** Séries diárias de valor (topo) e quantidade (base), com médias móveis de 5 e 20 dias. As linhas verticais marcam os dias de intervenção (incidentes e vésperas de feriado).

## 3 O sistema em produção: AutoML diário (TPOT)

O ponto de partida — e o *benchmark* a bater — é a rotina em produção (`scripts/producao/projecoes_qtd.py` e `projecoes_valor.py`), que roda todo dia útil e prevê o dia seguinte com um pipeline de *AutoML* (TPOT).

**Construção da base.** A cada execução, o script consulta o ClickHouse (propostas da etapa 16, em janelas de 15 minutos) e agrega por dia; toma os  $\approx 45$  dias úteis anteriores ao dia de referência (o último dia útil fechado). Os dias atípicos (`Log_Erro` + vésperas de feriado) são removidos antes de montar as defasagens, para não contaminarem nem o alvo nem os *lags* dos dias vizinhos.

**Engenharia de *features* (defasagens).** O modelo não é temporal por construção — a dinâmica é injetada como colunas de defasagem, mais o dia da semana:

- **Quantidade:** `dia_semana`, `lag_0`=valor de ontem, `lag_1..6`=quantidade dos 6 dias úteis anteriores. Alvo: quantidade.
- **Valor:** `dia_semana`, `lag_0`=quantidade de ontem, `lag_1..6`=valor dos 6 dias anteriores, e `lag_7`=fila de pagamento de ontem (etapa 15, 2º *query*). Alvo: valor.

**Busca AutoML e validação.** O TPOT faz busca evolutiva (*60 gerações, população 60*) sobre combinações de pré-processadores e regressores, otimizando um pipeline para o alvo. A validação é um teste de 1 dia (a última observação): calcula-se o **MAPE** e aceita-se o modelo se  $1\% \leq \text{MAPE} \leq 5\%$ ; caso contrário, retreina-se (até  $4\times$  na quantidade,  $3\times$  no valor). O pipeline aprovado é serializado em `modelos/{quantidade,valor}/` e o mais recente é carregado para prever o próximo dia útil, com o resultado registrado em `resultados/backup_{qtd,valor}.xlsx`.

**Limitações que motivam o estudo.** O TPOT é acurado, mas (i) é **caixa-preta** — a arquitetura empilhada não revela “quanto a fila pesa” ou “quanto um erro custa”; (ii) é **retreinado quase diariamente**, o que o torna caro, não-determinístico e difícil de auditar; e (iii) valida-se em um único ponto por dia, uma medida ruidosa de qualidade. Isso motiva buscar um modelo *fixo, rápido e interpretável* que iguale seu desempenho.

## 4 Seleção experimental de um modelo substituto

O objetivo do experimento (notebooks `experimento_qtd.ipynb` e `experimento_valor.ipynb`) é substituir o TPOT por um modelo confiável e rápido, comparando dezenas de candidatos sob um protocolo de avaliação honesto e idêntico para todos.

**Protocolo *walk-forward* alinhado ao histórico.** Cada candidato é avaliado com `TimeSeriesSplit(test_size=1, max_train_size=JANELA)` — um *fold* por dia do *backup*, retreinando na janela anterior e prevendo o próximo dia, sem jamais ver o futuro. A janela de datas é ancorada na *data mínima do backup*, para cobrir todo o período e comparar *maçã-com-maçã* com a **Pipeline Antiga** (as previsões que o TPOT realmente fez em produção). Todos os candidatos usam as *features* da Seção 3, exceto os modelos de série temporal, que aprendem a dinâmica diretamente.

**Famílias de candidatos.** O experimento é organizado em partes:

- **Parte 1 — modelos simples:** regressores com hiperparâmetros padrão (lineares, árvores, *gradient boosting*), um ponto de teste por dia.
- **Parte 2 — abordagens avançadas:** reproduzem, de forma transparente, o que o TPOT faz — seleção de variáveis (`SelectKBest`), *tuning* (`RandomizedSearchCV`), *ensembles* (`Voting/Stacking`) e *pipelines* com pré-processamento.

- **Parte 3 — *deep learning* e séries temporais:** LSTM, CNN 1D e *Transformer*; e modelos com dependência temporal explícita — **Auto-ARIMA**, **Prophet** e **NeuralProphet**. Também se avaliam **retrospectivamente** os próprios *pipelines* TPOT de produção (cada .pk1) nos mesmos *folds*.

**Exclusão de dias atípicos na avaliação.** Há uma distinção importante entre *estimar* e *avaliar*: os dias atípicos podem entrar no treino (no SARIMA, via intervenção), mas são **removidos do ranking**. Manter um dia de falha operacional na comparação penalizaria (ou premiaria) os modelos por ruído operacional, não por capacidade preditiva, distorcendo o MAPE/RMSPE. A remoção (`mask_dias_excluir`) segue três critérios: (i) **Log de Erro** — o dia do incidente e os  $n - 1$  dias úteis seguintes (coluna *impacto*, pois a fila represada “vaza” para os dias seguintes); (ii) **véspera de feriado** (Natal, Ano-Novo, Carnaval e o dia anterior); (iii) **outliers manuais** pontuais. A comparação usa as previsões *cruas* (sem correção de viés), sobre a mesma base comum de datas.

**Critério de seleção — por que RMSPE.** O *ranking* é ordenado por **RMSPE**, porque ele decompõe o erro em viés e dispersão:

$$\text{RMSPE} = \sqrt{\frac{1}{N} \sum_{t=1}^N \left( \frac{y_t - \hat{y}_t}{y_t} \right)^2}, \quad \underbrace{\text{RMSPE}^2}_{\text{erro total}} = \underbrace{\text{Viés}^2}_{\text{descentramento}} + \underbrace{\text{Dispersão}^2}_{\text{espalhamento}}. \quad (1)$$

Se o erro percentual fosse igual todo dia (dispersão = 0), teríamos  $\text{RMSPE} = \text{MAPE}$ ; quanto maior a dispersão, mais o RMSPE se afasta do MAPE. Exemplo: para APEs (0, 0, 6, 6),  $\text{MAPE} = 3$  e dispersão = 3, logo  $\text{RMSPE} = \sqrt{9 + 9} = 4,24\%$ . Assim o RMSPE **penaliza outliers** mais que o MAPE e captura o *trade-off viés × variância*. As demais métricas completam o retrato: MAPE (erro típico),  $R^2$ , Viés/MPE (erro sistemático), DP Erro, Máx.% (pior dia) e as frações de dias com erro < 5% / < 10%. Meta:  $\text{MAPE} \leq 5\%$  (ideal),  $\leq 10\%$  (aceitável).

**Do experimento à modelagem SARIMA.** O experimento mostrou que *nenhum* enriquecimento de *features* ou família de ML supera de forma consistente e interpretável os modelos de **série temporal clássica**: entre os candidatos que *igualam ou batem* a Pipeline Antiga, o **SARIMA** é o mais parcimonioso e o único totalmente auditável. Ele é, portanto, promovido de *benchmark* a **modelo recomendado** — e o restante do relatório o identifica, trata seus dias atípicos por intervenção e o estima e valida em detalhe.

## 5 Modelagem SARIMA: especificação, identificação e intervenção

### 5.1 O modelo SARIMA/SARIMAX

Seja  $B$  o operador de defasagem ( $B^k y_t = y_{t-k}$ ). Um modelo  $\text{SARIMA}(p, d, q)(P, D, Q)_s$  com regressores exógenos (SARIMAX) escreve-se como uma **regressão com erros SARIMA**:

$$y_t = \beta' \mathbf{X}_t + \eta_t, \quad \phi(B) \Phi(B^s) (1 - B)^d (1 - B^s)^D \eta_t = \theta(B) \Theta(B^s) \varepsilon_t, \quad (2)$$

onde  $\mathbf{X}_t$  reúne os regressores de intervenção (Seção 5.3),  $\varepsilon_t \sim \text{RB}(0, \sigma^2)$ , e  $\phi, \theta, \Phi, \Theta$  são, respectivamente, os polinômios autorregressivo e de média móvel não-sazonais e sazonais. Nesta aplicação  $s = 5$  e, como se verá,  $d = 1$ ,  $D = 0$ . Os dois modelos escolhidos são **SARIMA univariados** (não usam covariável de negócio): os únicos regressores em  $\mathbf{X}_t$  são as *dummies* de intervenção.

## 5.2 Identificação: estacionariedade e ordem

A identificação segue Box–Jenkins: (i) **estacionariedade** por ADF e KPSS; (ii) inspeção de **ACF/PACF** em nível e na primeira diferença; (iii) **decomposição STL** (período 5) para separar tendência, sazonal e resíduo. A ordem  $(p, d, q)(P, D, Q)_5$  é escolhida por **auto\_arima** (busca *stepwise* minimizando o AIC), *uma única vez*, sobre a série inteira — um vazamento *leve e restrito à especificação*; os **coeficientes**, porém, são reestimados honestamente a cada dia do *walk-forward* (MLE via filtro de Kalman, só com o passado — Seção 4).

## 5.3 Análise de intervenção (Box–Tiao)

Dias atípicos — incidentes operacionais registrados no **Log\_Erro** e vésperas de Natal/Ano-Novo/Carnaval — produzem *spikes* que, se ignorados, contaminam a estimação de  $\phi, \theta, \Phi, \Theta$ . Em vez de descartar esses dias da estimação, adota-se o **modelo de intervenção de Box–Tiao**: cada evento entra como um regressor determinístico cuja resposta dinâmica é uma *função de transferência* aplicada a um indicador de pulso

$$P_t = \mathbb{K}[t \in \mathcal{D}_E], \quad y_t = \frac{\omega(B)}{\delta(B)} B^b P_t + N_t, \quad (3)$$

onde  $\mathcal{D}_E$  é o conjunto de datas do evento  $E$ ,  $N_t$  é o ruído SARIMA de (2), e  $\frac{\omega(B)}{\delta(B)} B^b$  controla magnitude, atraso ( $b$ ) e persistência do efeito. Teoricamente, erros operacionais são *impulsos* (não deixam impacto permanente na série). As formas funcionais testadas por evento são casos particulares de (3), resumidas na Tabela 2.

**Tabela 2:** Famílias de função de intervenção testadas. O fator  $\delta \in (0, 1)$  controla a velocidade do decaimento;  $d_0 < \dots < d_{n-1}$  são os dias úteis afetados por um evento de duração  $n$ . A forma vencedora de cada evento é a de coeficiente(s) significativo(s) ( $p < 0,05$ ) e menor AIC; sem nenhum significativo  $\rightarrow$  “não signif.”; empate  $\rightarrow$  a mais simples.

| Forma           | Regressor                                                                       | Interpretação                                                      |
|-----------------|---------------------------------------------------------------------------------|--------------------------------------------------------------------|
| Abrupto         | $x_t = P_t$                                                                     | choque constante nos dias de impacto, retorno abrupto a zero       |
| Gradual         | $x_t = \frac{n-k}{n}, t = d_k$                                                  | rampa linear decrescente (1 no 1º dia $\rightarrow 1/n$ no último) |
| Rebote (2 reg.) | $x_t^{(1)} = \mathbb{K}[t = d_0], x_t^{(2)} = \mathbb{K}[t \in \{d_1, \dots\}]$ | queda no 1º dia + recuperação (sinais opostos) do <i>backlog</i>   |
| Transf. g       | $x_t = \delta x_{t-1} + P_t$                                                    | choque temporário com decaimento geométrico                        |
| Transf. b       | $x_t = \delta x_{t-1} + P_{t-1}$                                                | igual ao g, com atraso de um dia                                   |
| Transf. c       | $x_t = \sum_{\tau \leq t} P_\tau$                                               | degrau permanente (mudança de patamar)                             |
| Transf. e (2)   | $x_t^{(1)} = P_t, x_t^{(2)} = \delta x_{t-1}^{(2)} + P_t$                       | pulso imediato + cauda que decai                                   |
| Transf. d (2)   | $x_t^{(1)} = \delta x_{t-1}^{(1)} + P_t, x_t^{(2)} = \sum_{\tau \leq t} P_\tau$ | transitório que decai + degrau permanente                          |
| Transf. f       | $x_t = \sum_{\tau \leq t} v_\tau, v_\tau = \delta v_{\tau-1} + P_\tau$          | convergência suave a um novo patamar                               |

Cada **tipo** de dia atípico é classificado de forma *independente* por série: as vésperas de feriado são separadas em “dia anterior à véspera” (D-1) e “véspera” propriamente, e cada uma — assim como cada incidente do **Log\_Erro** — pode receber uma forma diferente no valor e na quantidade.

A intervenção **mantém** os dias especiais no treino (necessário para estimar o efeito), mas nos dias de avaliação (normais) as *dummies* valem zero. Assim, os coeficientes AR/MA descrevem a *dinâmica normal* da série, e cada choque atípico recebe um coeficiente e um *p*-valor próprios — exatamente o que a caixa-preta não oferece.


## 5.4 Cointegração

Como valor e quantidade parecem “andar juntas”, testa-se se há **equilíbrio de longo prazo** entre elas. Se forem cointegradas com vetor  $(1, -\beta)$ , o *ticket médio* (valor/qtd) seria estacionário. Aplicam-se **Engle–Granger** e **Johansen** (traço) sobre os níveis, com seleção prévia do *lag* do VAR por critério de informação, mais o ADF do *ticket médio* e o ADF com tendência (ct) para descartar *trend-stationarity*. Antes dos testes, remove-se dos níveis o efeito de *pulso* dos dias atípicos. O teste decide se as séries devem ser modeladas *juntas* (VECM/ARDL) ou *separadamente*.

# 6 Resultados

## 6.1 Identificação e estacionariedade

A ACF em nível decai lentamente nas duas séries (não-estacionariedade), justificando  $d = 1$ ; na primeira diferença surge um pico negativo no *lag* 1 — assinatura de **MA(1)** (Figura 2). A **decomposição STL** (período 5) confirma o padrão nas duas séries (Figuras 3 e 4): **tendência** suave de médio prazo, **sazonalidade semanal** clara e **resíduo** com *spikes* concentrados nos dias atípicos (que a intervenção trata). A ordem selecionada foi SARIMA(0, 1, 1)(0, 0, 1)<sub>5</sub> para o valor e (0, 1, 1)(0, 0, 2)<sub>5</sub> para a quantidade.




**Figura 2:** ACF/PACF do valor: nível decai lentamente ( $I(1)$ ); a 1ª diferença apresenta corte no *lag* 1, sugerindo MA(1). Padrão análogo na quantidade.





**Figura 3:** Decomposição STL (período 5) da série de **valor**: observado, tendência, sazonal semanal e resíduo. A tendência sobe ao longo de 2025–2026; o resíduo concentra os *spikes* nos dias atípicos.




**Figura 4:** Decomposição STL (período 5) da série de **quantidade**: mesmo padrão (tendência + sazonal semanal + resíduo com *spikes*), com histórico ligeiramente mais curto.

## 6.2 Cointegração: não há equilíbrio de longo prazo

Após remover o pulso dos dias atípicos, Engle–Granger **não rejeita** a ausência de cointegração (estatística =  $-0,60$ ,  $p = 0,956$ ) e o ADF do *ticket* médio indica erro de equilíbrio não-estacionário ( $p = 0,790$ ) — Tabela 3. O Johansen sem tendência aponta 0 relações; com tendência determinística aponta 2, mas isso coincide com a *trend-stationarity* detectada pelo ADF-ct, ou seja, *não* é cointegração genuína. A relação estimada foi  $\text{valor} = -1.536.713 + 2.220,46 \cdot \text{qtd}$  ( $\beta \approx \text{ticket}$  médio), mas seu resíduo **deriva** ao longo do tempo (Figura 5).

**Tabela 3:** Testes de raiz unitária e cointegração (níveis ajustados para intervenção).

| Teste                         | Valor        | Quantidade   | Leitura                                      |
|-------------------------------|--------------|--------------|----------------------------------------------|
| ADF nível                     | $p = 0,060$  | $p = 0,0005$ | valor $I(1)$ ù qtd $I(0)$ (ordens mistas)    |
| ADF 1ª dif.                   | $p = 0,000$  | $p = 0,000$  | ambas estacionárias diferenciadas            |
| ADF-ct                        | $p = 0,0004$ | $p = 0,0003$ | ambas <i>trend-stationary</i>                |
| Engle–Granger (−0,60)         | $p = 0,956$  |              | <b>não rejeita</b> → sem cointegração        |
| ADF do <i>ticket</i> médio    | $p = 0,790$  |              | erro de equilíbrio não-estacionário          |
| ARDL <i>bounds</i> (caso III) | $F = 2,34$   | $F = 2,66$   | $F < I(0)_{5\%} = 3,80$ → <b>não rejeita</b> |



**Figura 5:** Superior: valor e quantidade padronizados ( $z$ -score), dias atípicos ajustados em vermelho. Inferior: resíduo de Engle–Granger — **deriva** em vez de oscilar em torno de zero, evidência visual da ausência de cointegração.

**Follow-up formal (ARDL).** Como as ordens de integração são **mistas**  $I(0)/I(1)$ , o teste apropriado dispensa a pré-classificação em  $I(1)$ : o **teste de limites** de Pesaran–Shin–Smith (*bounds test*), que verifica a existência de uma *relação de nível*. Nas duas direções a estatística  $F$  (2,34 para valor|qtd; 2,66 para qtd|valor) fica **abaixo do limite inferior**  $I(0)$  a 5% (3,80) — **não se rejeita** a ausência de relação de nível, **confirmando** Engle–Granger e Johansen (Tabela 3).

### Por que a rejeição faz sentido, e como (não) modelar as séries juntas

À primeira vista valor e quantidade “andam juntas” e a tentação é modelá-las conjuntamente. O ponto é que **co-movimento contemporâneo**  $\neq$  **cointegração**. Cointegração descreve um *equilíbrio de longo prazo*: um desvio entre as séries hoje é *corrigido ao longo dos dias* (mecanismo de correção de erro) — um fenômeno *defasado*. A relação valor–quantidade, porém, é quase a identidade contábil *contemporânea*  $\text{valor}_t \approx \bar{t}_t \cdot \text{qtd}_t$  (com  $\bar{t} = \text{ticket}$  médio do dia): mais propostas hoje → mais valor *hoje*, no mesmo dia, sem desequilíbrio que leve dias para se dissipar. Somando-se a isso que o ADF-ct aponta as séries como *trend-stationary* (próximas de  $I(0)$ ), e que cointegração — definida apenas para séries  $I(1)$  — torna-se *inaplicável*, a rejeição é o resultado **esperado**, não um fracasso: ela só descarta a família VECM/correção de erro.

Rejeitar cointegração não impede modelagem conjunta — muda apenas *qual* modelo é apropriado. Três alternativas foram testadas no **mesmo walk-forward 1-passo e nas mesmas datas** do *ranking* univariado (contraste controlado, todas sem *dummies* de intervenção):

1. **(a) Decomposição por ticket** —  $\text{valor} = \text{qtd} \times \text{ticket}$ : prevê-se qtd e *ticket* (= valor/qtd) por SARIMA e recompõe-se  $\hat{v} = \hat{q} \cdot \hat{t}$ . Usa a identidade estrutural, mas *exige prever qtd primeiro* (sistema encadeado); só se aplica ao valor.



2. **(b) SUR bivariado** — duas equações com regressores próprios defasados + *dummies* de dia-da-semana, estimadas em conjunto (FGLS de Zellner) com erros correlacionados.
3. **(c) VAR em diferenças** — o modelo conjunto *clássico quando não há cointegração* (VAR nas 1<sup>as</sup> diferenças, não VECM), com *dummies* semanais como exógenas.
4. **(d) ARDL encadeado** — regressão ARDL de uma série sobre *lags* da outra, com o termo contemporâneo substituído pela previsão univariada da outra série (sem vazamento); a contraparte *preditiva* do teste de limites ARDL acima.

A Tabela 4 traz o resultado. **O SARIMA univariado é o mais adequado.** Na quantidade ele vence na frente (RMSPE 9,07% contra 9,24% do ARDL, 9,49% do VAR e 10,80% do SUR). No valor, *ticket* e *ARDL encadeado* apenas *empatam* (9,44% e 9,51% vs. 9,58%,  $\approx 0,1$  p.p., dentro do ruído amostral) — e nem são modelos de dinâmica conjunta: usam a identidade estrutural e ainda precisam prever a quantidade antes ( $\hat{q}$ ). Já **SUR e VAR pioram** nas duas séries. O motivo confirma a leitura da cointegração: o elo forte é *contemporâneo* e, portanto, *inutilizável* para prever D+1 (não se conhece o qtd de amanhã ao prever o valor); resta o elo *defasado*, fraco, cujos termos cruzados só adicionam **variância** sem reduzir viés. Sem correção de erro (i.e. sem cointegração), a informação cruzada não carrega conteúdo preditivo — apenas ruído.

**Tabela 4:** Modelagem conjunta vs. univariada — walk-forward 1-passo, mesmas janelas (sem intervenção). Menor RMSPE por série em negrito.

| Série             | Modelo                                               | RMSPE (%)   | MAPE (%) | $R^2$ |
|-------------------|------------------------------------------------------|-------------|----------|-------|
| Valor ( $N=209$ ) | <b>(a) Ticket <math>\hat{q} \cdot \hat{t}</math></b> | <b>9,44</b> | 7,51     | 0,744 |
|                   | (d) ARDL valor $\leftarrow$ qtd                      | 9,51        | 7,47     | 0,743 |
|                   | SARIMA univariado                                    | 9,58        | 7,71     | 0,730 |
|                   | (c) VAR em diferenças                                | 9,89        | 7,75     | 0,701 |
|                   | (b) SUR bivariado                                    | 11,84       | 9,24     | 0,555 |
| Qtd. ( $N=211$ )  | <b>SARIMA univariado</b>                             | <b>9,07</b> | 7,32     | 0,399 |
|                   | (d) ARDL qtd $\leftarrow$ valor                      | 9,24        | 7,56     | 0,372 |
|                   | (c) VAR em diferenças                                | 9,49        | 7,31     | 0,335 |
|                   | (b) SUR bivariado                                    | 10,80       | 8,62     | 0,102 |

**Consequência metodológica:** como o erro de equilíbrio não reverte à média, o teste de limites ARDL *não rejeita* a ausência de relação de nível e *nenhum* modelo conjunto supera o univariado, *modelam-se as séries separadamente* (SARIMA univariado + intervenção). As alternativas conjuntas ou empatam (*ticket*/ARDL, estruturais e encadeados) ou pioram (SUR/VAR). O *follow-up* formal apropriado ao caráter misto  $I(0)/I(1)$  é justamente o ARDL (Pesaran–Shin–Smith), não o VECM — e foi ele que fechou o argumento.


### 6.3 Intervenção: classificação por evento e descontaminação do ajuste

No modelo congelado de produção, **23 janelas de evento** foram classificadas em cada série — os 17 incidentes operacionais do Log\_Erro mais 6 janelas de véspera de feriado (o “dia anterior” D-1 e a “véspera”, para Natal, Ano-Novo e Carnaval). A escolha da forma vencedora é feita *por série de forma independente*; a Tabela 5 resume a distribuição das formas, a Figura 6 traz a **magnitude do efeito** evento a evento, e a Figura 7 mostra os **eventos ao longo do tempo** sobre as séries.


**Tabela 5:** Distribuição das formas de intervenção escolhidas (função vencedora por AIC), por série — fonte: `config/modelo_sarima_producao.json`. As 23 janelas incluem os 17 incidentes do `Log_Erro` e 6 janelas de véspera.

| Forma de intervenção         | Valor ( $n$ ) | Quantidade ( $n$ ) |
|------------------------------|---------------|--------------------|
| Abrupto (choque pontual)     | 5             | 3                  |
| Gradual (rampa decrescente)  | 5             | 0                  |
| Rebote (queda + recuperação) | 2             | 0                  |
| $b$ (geom. com atraso 1 dia) | 3             | 4                  |
| $c$ (degrau permanente)      | 0             | 3                  |
| $e$ (pulso + cauda)          | 3             | 2                  |
| $f$ (patamar suave)          | 1             | 2                  |
| $g$ (decaimento geométrico)  | 1             | 1                  |
| Não signif. (descartado)     | 3             | 8                  |
| <b>Total</b>                 | <b>23</b>     | <b>23</b>          |

Dois padrões chamam a atenção. Primeiro, **muitos incidentes afetam o valor mas não a quantidade**: são 8/23 janelas “não signif.” na quantidade contra apenas 3/23 no valor — uma parada operacional muda o *quanto* é processado sem necessariamente mudar *quantas* propostas entram. Segundo, predominam formas com **decaimento/cauda** ( $b$ ,  $g$ ,  $e$ ,  $f$ ) em vez do choque puramente abrupto: o efeito de um erro não some de um dia para o outro — há *backlog* processado nos dias seguintes. As vésperas seguem padrão próprio: o dia anterior (D-1) é um pulso com cauda ( $e$ ,  $\delta = 0,1$ ) nas duas séries, enquanto a véspera de Natal e de Ano-Novo é um choque **abrupto**; o Carnaval difere entre séries.




**Figura 6:** Magnitude do efeito estimado (coeficiente principal da função vencedora) por evento, para o **valor** (topo) e a **quantidade** (base); a cor indica a forma de intervenção vencedora. Os efeitos são predominantemente negativos (paradas derrubam a série); as vésperas de Natal/Ano-Novo têm forte componente de cauda (função *e*), e vários incidentes que pesam no valor são *não signif.* na quantidade.




**Figura 7:** Eventos de intervenção ao longo do histórico, sobre as séries de valor (topo) e quantidade (base). Cada ponto marca um dia de evento, colorido pela **função vencedora** (mesmo código da Figura 6); os pontos cinza (“não signif.”) foram testados e descartados. Fonte: modelo congelado de produção.

O efeito da intervenção sobre a *qualidade do ajuste* é um dos resultados centrais: com as *dummies*, o **Ljung–Box deixa de rejeitar** a hipótese de resíduos não-autocorrelacionados — o  $p(10)$  sobe de  $\approx 0,01$  (sem intervenção, em ambas as séries) para **0,37** (valor) e **0,63** (quantidade), como mostra a Tabela 6. Isso fica visual de duas formas. (i) **No tempo:** o resíduo *pré* intervenção tem *spikes* enormes exatamente nos dias de *Log\_Erro* e *véspera* (linhas marcadas); *pós* intervenção esses picos desaparecem e o resíduo fica homogêneo (Figuras 8 e 9). (ii) **Na distribuição:** no *plot\_diagnostics* (Figuras 10 e 11), antes da intervenção o **Q–Q** exibe uma cauda inferior pesada e o **histograma** é leptocúrtico; depois, os resíduos se aproximam nitidamente da normal. Persistem, como ressalva, **heterocedasticidade** e **caudas pesadas** residuais (Jarque–Bera significativo) — erros maiores nos dias atípicos —, o que torna os intervalos de confiança otimistas nos extremos.




**Figura 8:** Resíduo do SARIMA de **valor** ao longo do tempo, *pré* (topo, com os dias de *Log\_Erro* e *véspera* marcados) vs. *pós* intervenção (base). Os *spikes* nos dias atípicos somem após o tratamento.



**Figura 9:** Resíduo do SARIMA de **quantidade** ao longo do tempo, *pré* vs. *pós* intervenção. Mesmo efeito: os picos dos dias atípicos são absorvidos.


### Valor (R\$): distribuição dos resíduos — pré vs. pós intervenção



**Figura 10:** Distribuição dos resíduos do SARIMA de **valor** — histograma (topo) e Q-Q normal (base), *pré* (esquerda) vs. *pós* (direita) intervenção. A cauda inferior pesada do Q-Q (dias de erro puxando os resíduos) some após a intervenção, e o histograma se aproxima da  $N(0,1)$ .



## Quantidade de propostas: distribuição dos resíduos — pré vs. pós intervenção



**Figura 11:** Distribuição dos resíduos do SARIMA de **quantidade** — histograma (topo) e Q-Q normal (base), *pré* vs. *pós* intervenção. Mesmo padrão: os resíduos se aproximam da normal após tratar os dias atípicos.

### 6.4 Estimação: coeficientes e significância

A Tabela 6 traz o ajuste *in-sample* do modelo congelado (regressão com erros SARIMA + intervenção,  $N = 414$ ). O achado central é econométrico: o **motor preditivo é a MA(1)**, não a sazonalidade. O termo  $\theta_1 \approx -0,6$  é grande e altamente significativo ( $p < 0,001$ ) nas duas séries — de longe o coeficiente mais forte. Num IMA(1,1), isso equivale a uma **suavização do tipo média móvel exponencial**: a previsão de amanhã é o nível de hoje corrigido por  $\approx 60\%$  do erro de previsão de ontem. A **sazonalidade semanal é real, mas fraca** ( $\Theta$  pequenos e não significativos individualmente,  $p \geq 0,11$ ): a maior parte do padrão semanal já é absorvida pela diferenciação e pela grade de dias úteis.

**Tabela 6:** Coeficientes *in-sample* do modelo congelado ( $N = 414$  dias úteis) e diagnóstico de Ljung–Box. Fonte: docs/modelo\_sarima\_intervencoes.md.

| Termo                                | Valor (0, 1, 1)(0, 0, 1) <sub>5</sub> | Qtd (0, 1, 1)(0, 0, 2) <sub>5</sub> |
|--------------------------------------|---------------------------------------|-------------------------------------|
| MA(1) — $\theta_1$ (choque de ontem) | <b>-0,645</b> ũ $p < 0,001$           | <b>-0,605</b> ũ $p < 0,001$         |
| MA sazonal — $\Theta_1$ (lag 5)      | -0,074 ũ $p = 0,11$                   | -0,035 ũ $p = 0,47$                 |
| MA sazonal — $\Theta_2$ (lag 10)     | —                                     | +0,014 ũ $p = 0,79$                 |
| AIC                                  | 11.796,7                              | 5.661,2                             |
| Ljung–Box $p(10)$ (com interv.)      | <b>0,37</b> ✓                         | <b>0,63</b> ✓                       |
| Ljung–Box $p(10)$ (sem interv.)      | $\approx 0,01$ ✗                      | $\approx 0,01$ ✗                    |

### 6.5 Ranking diário — histórico completo

Sob o mesmo protocolo *walk-forward*, o SARIMA compete com a pipeline antiga e com os melhores modelos de ML/TPOT. Os resultados diferem entre as séries e merecem leitura cuidadosa.

**Valor (Tabela 7).** O SARIMA é o **1º colocado**: melhor RMSPE (9,36%), melhor  $R^2$  (0,750), menor viés (praticamente zero:  $-594$  vs.  $+29.991$  da antiga) e menor erro máximo (30,52% vs. 39,52%). Perde por pouco no MAPE médio para a antiga (7,35% vs. 7,19%). É uma vitória limpa, e com viés quase nulo.

**Tabela 7:** *Ranking* — Valor (histórico completo, ordenado por RMSPE). Viés e DP Erro em R\$.


| Modelo                      | MAPE%       | RMSPE%      | $R^2$        | Viés        | Máx.%        | <10%           |
|-----------------------------|-------------|-------------|--------------|-------------|--------------|----------------|
| <b>SARIMA</b>               | 7,35        | <b>9,36</b> | <b>0,750</b> | <b>-594</b> | <b>30,52</b> | 152/209        |
| Pipeline Antiga em Produção | <b>7,19</b> | 9,54        | 0,748        | +29.991     | 39,52        | 156/211        |
| ExtraTrees (EXT, j90)       | 7,20        | 9,61        | 0,720        | +79.401     | 42,56        | <b>164/209</b> |
| POLY+ABR                    | 8,12        | 10,33       | 0,684        | +113.975    | 32,44        | 144/209        |
| Voting (GBR+XGB+RFR)        | 7,97        | 10,65       | 0,660        | +134.676    | 33,35        | 146/209        |

**Quantidade (Tabela 8).** Aqui a leitura é *mista* e o relatório é honesto quanto a isso. O SARIMA tem o **melhor MAPE médio (7,19%)**, o **menor viés (22,6)** — centradíssimo — e o **maior número de dias muito bons** (97/211 com erro < 5%). Porém, no critério de *ranking* (RMSPE) fica em 4º (9,64% vs. 9,49% do melhor ML) e tem o **pior erro máximo (50,71%)**: um único dia muito ruim (justamente o que o RMSPE penaliza). Ou seja, o SARIMA é o *mais bem centrado*, mas não o de menor dispersão de cauda na quantidade — ainda assim supera a pipeline antiga em RMSPE (9,64 vs. 9,88) e em MAPE.

**Tabela 8:** *Ranking* — Quantidade (histórico completo,  $N = 211$ , ordenado por RMSPE).

| Modelo                       | MAPE%       | RMSPE%      | $R^2$ | Viés        | Máx.% | <5%       |
|------------------------------|-------------|-------------|-------|-------------|-------|-----------|
| SE(LINE)+SE(SGDR)+ABR        | 7,41        | <b>9,49</b> | 0,345 | 59,6        | 31,26 | 88        |
| SPct+ABR                     | 7,47        | 9,59        | 0,336 | 61,0        | 31,26 | 85        |
| SE(ABR)+MAS+OHE+ABR          | 7,32        | 9,62        | 0,328 | 43,7        | 34,42 | 96        |
| <b>SARIMA</b>                | <b>7,19</b> | 9,64        | 0,339 | <b>22,6</b> | 50,71 | <b>97</b> |
| SE(ETR)+MMS+BIN+SE(ELAS)+ABR | 7,67        | 9,73        | 0,311 | 69,9        | 29,60 | 85        |
| Pipeline Antiga em Produção  | 7,89        | 9,88        | 0,313 | 40,5        | 34,06 | 87        |

No **recorte recente (janeiro em diante)** a vantagem dos modelos brancos cresce e fica mais estável. O acompanhamento do previsto  $\times$  realizado (Figura 12) mostra que o SARIMA segue bem nível e sazonalidade, com os maiores erros nos saltos pós-atípicos — onde a pipeline antiga também erra.



**Figura 12:** Valor previsto (SARIMA)  $\times$  realizado  $\times$  pipeline antiga ao longo do período de avaliação. Os maiores erros concentram-se nos saltos pós-atípicos.

## 6.6 Modelos mensais: *nowcast* e comparação

Como extensão, estuda-se a previsão do **total do mês**. O *nowcast* soma o realizado acumulado até o dia  $D$  à previsão SARIMA dos dias úteis restantes:  $\text{Nowcast}(D) = \text{acumulado}(\leq D) + \text{restante}$ ; conforme o mês avança, mais dias viram realizado e a estimativa converge (Figura 13). Agregando os 19 meses completos, o  $|\text{Erro } \%|$  mediano começa em  $\approx 5\text{--}7\%$  e cai para  $< 2\%$  a partir de  $\approx 2/3$  do mês.


Comparando abordagens de total mensal (Tabelas 9 e 10), **um resultado honesto se impõe**: para o total mensal, a *persistência* ingênua (**Naive**, repetir o mês anterior) é a melhor, e o modelo paramétrico direto (ARIMAX) é o *pior*. O *nowcast* fica em posição intermediária — útil por atualizar em tempo real ao longo do mês, mas não a melhor previsão *a priori* do total.

**Tabela 9:** Total mensal — **Valor**. Ordenado por RMSPE. (Viés em R\$.)

| Modelo                   | MAPE%       | RMSPE%      | Mediana% | Máx.%       | $R^2$        |
|--------------------------|-------------|-------------|----------|-------------|--------------|
| <b>Naive (mês−1)</b>     | <b>3,53</b> | <b>4,66</b> | 2,33     | <b>9,50</b> | <b>0,641</b> |
| Nowcast (últ. dia mês−1) | 4,43        | 5,27        | 4,17     | 11,04       | 0,547        |
| MediaUtil MM3            | 6,17        | 6,92        | 5,29     | 11,80       | 0,280        |
| ARIMAX                   | 7,70        | 8,53        | 7,77     | 14,18       | −0,078       |

**Tabela 10:** Total mensal — **Quantidade**. Ordenado por RMSPE.

| Modelo                   | MAPE%       | RMSPE%      | Mediana% | Máx.%       | $R^2$        |
|--------------------------|-------------|-------------|----------|-------------|--------------|
| <b>Naive (mês−1)</b>     | <b>2,94</b> | <b>3,64</b> | 2,80     | <b>6,89</b> | <b>0,597</b> |
| MediaUtil MM3            | 3,27        | 4,06        | 2,77     | 7,19        | 0,519        |
| Nowcast (últ. dia mês−1) | 4,19        | 4,57        | 3,82     | 7,80        | 0,368        |
| ARIMAX                   | 5,49        | 6,55        | 3,65     | 11,17       | −0,277       |



**Figura 13:** Trajetória mediana do erro percentual do *nowcast* ao longo do mês (faixa: IQR 25–75% entre meses), valor e quantidade.

## 7 Discussão e interpretação

Os modelos revelam, com significância estatística:

1. **As séries têm nível que passeia**, não uma média fixa ( $I(1)$ ): a melhor âncora para amanhã é o nível de hoje, não uma média histórica.
2. **O motor é a MA(1)**, não a sazonalidade:  $\theta_1 \approx -0,6$  ( $p < 0,001$ ) domina; o padrão semanal é real mas fraco.

3. **Dias de erro têm efeito real e mensurável** — entram como *intervenção*, não como descarte. Muitos afetam o *valor* sem afetar a *quantidade* (8/23 “não signif.” na qtd), e o efeito tipicamente tem cauda (*backlog*).
4. **Valor e quantidade não compartilham equilíbrio de longo prazo** — a modelagem separada é a escolha correta.

**Leitura crítica.** O argumento a favor do modelo branco é **forte no valor** (SARIMA 1º em RMSPE,  $R^2$ , viés e erro máximo) e **qualitativamente forte nas duas séries** (interpretabilidade, diagnóstico de Ljung–Box, especificação congelada). Deve-se ser honesto, porém, em dois pontos: (i) na **quantidade**, o SARIMA *não* é o melhor no critério de *ranking* (RMSPE 9,64%, 4º) e tem o *pior* erro máximo (50,71%) — é o mais bem centrado (menor viés, melhor MAPE), mas paga em um dia de cauda; (ii) o **ganho de acurácia** sobre a pipeline antiga é, no geral, *marginal*. A tese que se sustenta com robustez não é “prevê muito melhor”, e sim “**empata ou supera em acurácia e ganha em interpretabilidade, auditabilidade e tratamento explícito de choques**”, com a vantagem operacional de uma *única* especificação congelada contra o retreino diário da caixa-preta. Nos **totais mensais**, a recomendação prática é a persistência (Naive)/nowcast, não o paramétrico direto.

## 8 Conclusão

- **Valor** → SARIMA (0, 1, 1)(0, 0, 1)<sub>5</sub> + intervenção: 1º no *ranking*, melhor RMSPE (9,36%),  $R^2$  (0,750) e viés quase nulo.
- **Quantidade** → SARIMA (0, 1, 1)(0, 0, 2)<sub>5</sub> + intervenção: melhor MAPE e viés, supera a pipeline antiga em RMSPE; univariado e parcimonioso.

Responde-se afirmativamente à pergunta de pesquisa: um modelo *branco*, com especificação única congelada, **igual ou supera** a pipeline em produção nas duas séries, sem abrir mão de interpretabilidade. A análise de intervenção de Box–Tiao mostrou-se decisiva para desconaminar o ajuste (Ljung–Box de  $\approx 0,01$  para 0,37/0,63) e a ausência de cointegração legitimou a modelagem separada — confirmada pelo teste de limites **ARDL** (que também não rejeita a ausência de relação de nível) e, empiricamente, pelo *walk-forward*, já que nenhuma alternativa conjunta (ticket, ARDL, SUR ou VAR) supera o SARIMA univariado (Tabela 4). Em uma frase: *ambas as séries são bem descritas por uma suavização MA(1) sobre a série diferenciada, com sazonalidade semanal leve e os dias atípicos tratados explicitamente por intervenção de Box–Tiao*.

**Limitações e próximos passos.** (i) **Heterocedasticidade e caudas pesadas** nos resíduos tornam os intervalos de confiança otimistas nos extremos — modelar a variância (**GARCH**) daria IC honestos também para os dias típicos; (ii) a modelagem *conjunta* poderia ainda ser explorada por um **modelo de fator dinâmico** ou por SUR com covariância de erro plena (útil para *intervalos conjuntos*, ainda que sem ganho de ponto esperado, dado o elo contemporâneo); (iii) validar e aprimorar os **modelos mensais** (o Naive vencer sugere reavaliar o nowcast como acompanhamento, não como previsão *a priori*); (iv) a classe da intervenção é fixada uma vez na série inteira (*look-ahead* estrutural leve, mitigado por ser majoritariamente calendário).

## Referências

- Box, G. E. P.; Jenkins, G. M.; Reinsel, G. C. *Time Series Analysis: Forecasting and Control*. Wiley.
- Box, G. E. P.; Tiao, G. C. (1975). *Intervention Analysis with Applications to Economic and Environmental Problems*. JASA, 70(349), 70–79.

- Engle, R. F.; Granger, C. W. J. (1987). *Co-integration and Error Correction*. *Econometrica*, 55(2), 251–276.
- Johansen, S. (1991). *Estimation and Hypothesis Testing of Cointegration Vectors in Gaussian VAR Models*. *Econometrica*, 59(6), 1551–1580.
- Pesaran, M. H.; Shin, Y.; Smith, R. J. (2001). *Bounds Testing Approaches to the Analysis of Level Relationships*. *J. Applied Econometrics*, 16(3), 289–326.
- Apresentação de referência: *Projeção de Vendas — Definição de Modelo (v2)*.
- Documentação interna do projeto: `docs/apresentacao_sarima_valor.md`, `docs/modelo_sarima_intervencoes.md`, `config/modelo_sarima_producao.json`.