

Previsão de Vendas Diárias de Propostas de Crédito: do AutoML à Econometria Interpretável

Construção da base, seleção experimental de modelos (TPOT $\rightarrow$ *walk-forward*) e
modelagem SARIMA com análise de intervenção de Box–Tiao

Daniel Ramazzotte

Disciplina: Econometria e Análise de Intervenção

Julho de 2026

Resumo

Este trabalho aplica a metodologia clássica de Box–Jenkins, estendida pela análise de intervenção de Box–Tiao e por testes de cointegração, à previsão diária de duas séries operacionais de uma financeira de crédito: o *valor* monetário e a *quantidade* de propostas processadas por dia útil. O objetivo é testar se um modelo *branco* (interpretável) do tipo SARIMA, com uma *única especificação congelada*, consegue igualar ou superar o sistema de *AutoML* (TPOT) atualmente em produção, que é retreinado quase diariamente. As séries são identificadas como $I(1)$ com sazonalidade semanal de dias úteis ($s = 5$); os dias atípicos (incidentes operacionais e vésperas de feriado) são tratados por funções de transferência de intervenção em vez de descartados da estimação. A validação usa *walk-forward* de um passo à frente, sem vazamento, e o critério de seleção é o RMSPE — justificado por decompor o erro em viés e dispersão. Os principais resultados: (i) **não há cointegração** confiável entre valor e quantidade, legitimando a modelagem separada; (ii) a intervenção **descontamina o ajuste** — o teste de Ljung–Box deixa de rejeitar a hipótese de resíduos não-autocorrelacionados ($p(10)$ de $\approx 0,01$ para 0,32 e 0,99); e (iii) o SARIMA **igualava ou supera** a pipeline em produção no RMSPE nas duas séries, preservando interpretabilidade estatística de cada componente.

Palavras-chave: SARIMA; análise de intervenção; Box–Tiao; cointegração; RMSPE; *walk-forward*; previsão de vendas.

1 Introdução

A área de crédito precisa antecipar, todo dia útil, duas grandezas operacionais distintas para o dia seguinte. A **quantidade** de propostas dimensiona a equipe e a fila de análise (capacidade de atendimento); o **valor** monetário dimensiona capital, caixa e risco. Ambas já são previstas em produção por um pipeline de *AutoML* (TPOT) — uma busca automatizada entre milhares de combinações de *features* e algoritmos de *machine learning*, *retreinado quase diariamente*. O pipeline é acurado, mas é uma **caixa-preta**: dele não se lê “quanto a fila pesa” nem “quanto um erro operacional custa” na previsão, e o retreino diário o torna caro e difícil de auditar.

O estudo em três atos. Este trabalho percorre a evolução completa do sistema de previsão:

1. **O baseline em produção** (Seção 3): a rotina diária de *AutoML* (TPOT), sua construção de base e engenharia de *features* por defasagens, e seus limites (caixa-preta, retreino diário).
2. **A seleção experimental** (Seção 4): um experimento controlado que compara dezenas de candidatos (modelos simples, *ensembles*, *deep learning* e séries temporais clássicas) sob *walk-forward* alinhado ao histórico, com o objetivo de *substituir o TPOT por um modelo fixo, rápido e confiável*.
3. **A modelagem econométrica** (Seções 5 em diante): o vencedor interpretável — um **SARIMA com análise de intervenção de Box–Tiao** — é então identificado, diagnosticado e estimado em detalhe.

Pergunta de pesquisa. Um modelo econométrico *clássico* de séries temporais (SARIMA), com estrutura interpretável e uma *única* especificação fixa (não retreinada a cada dia, apenas reestimada), consegue *igualar ou superar* a pipeline TPOT em produção nas duas séries que ela já prevê? Se o modelo branco vencer ou empatar, ganha-se interpretabilidade sem sacrificar acurácia: coeficientes com significância estatística, tratamento transparente dos dias atípicos (intervenção de Box–Tiao em vez de descarte cego) e um modelo auditável.

2 Dados e construção da base

As propostas (etapa 16) são agregadas em frequência **diária**, apenas em **dias úteis** (excluindo sábados, domingos e feriados nacionais via `workdays`). A ausência de feriados na grade produz uma sazonalidade semanal regular de período $s = 5$. A Tabela 1 resume as duas séries-alvo.

Tabela 1: Definição das séries-alvo. As duas têm o mesmo *status*: cada uma recebe seleção de ordem, intervenção, *ranking* e modelo recomendado próprios.

	Valor (R\$)	Quantidade
Definição	valor monetário processado no dia	nº de propostas analisadas no dia
Papel	série-alvo	série-alvo
Histórico	407 dias úteis (22/11/2024 → 08/07/2026)	
Janela <i>walk-forward</i>	$N = 259$	$N = 211$

Ambas exibem **nível que passeia** (não-estacionariedade), **sazonalidade semanal** e **que-das pontuais** nos dias de erro operacional (Figura 1).




Figura 1: Séries diárias de valor (topo) e quantidade (base), com médias móveis de 5 e 20 dias. As linhas verticais marcam os dias de intervenção (incidentes e vésperas de feriado).

3 O sistema em produção: AutoML diário (TPOT)

O ponto de partida — e o *benchmark* a bater — é a rotina em produção (`scripts/producao/projecoes_qtd.py` e `projecoes_valor.py`), que roda todo dia útil e prevê o dia seguinte com um pipeline de *AutoML* (TPOT).

Construção da base. A cada execução, o script consulta o ClickHouse (propostas da etapa 16, em janelas de 15 minutos) e agrega por dia; toma os ≈ 45 dias úteis anteriores ao dia de referência (o último dia útil fechado). Os dias atípicos (`Log_Erro` + vésperas de feriado) são removidos antes de montar as defasagens, para não contaminarem nem o alvo nem os *lags* dos dias vizinhos.

Engenharia de *features* (defasagens). O modelo não é temporal por construção — a dinâmica é injetada como colunas de defasagem, mais o dia da semana:

- **Quantidade:** `dia_semana`, `lag_0`=valor de ontem, `lag_1..6`=quantidade dos 6 dias úteis anteriores. Alvo: quantidade.
- **Valor:** `dia_semana`, `lag_0`=quantidade de ontem, `lag_1..6`=valor dos 6 dias anteriores, e `lag_7`=fila de pagamento de ontem (etapa 15, 2º *query*). Alvo: valor.

Busca AutoML e validação. O TPOT faz busca evolutiva (60 gerações, população 60) sobre combinações de pré-processadores e regressores, otimizando um pipeline para o alvo. A validação é um teste de 1 dia (a última observação): calcula-se o **MAPE** e aceita-se o modelo se $1\% \leq \text{MAPE} \leq 5\%$; caso contrário, retreina-se (até $4\times$ na quantidade, $3\times$ no valor). O pipeline aprovado é serializado em `modelos/{quantidade,valor}/` e o mais recente é carregado para prever o próximo dia útil, com o resultado registrado em `resultados/backup_{qtd,valor}.xlsx`.

Limitações que motivam o estudo. O TPOT é acurado, mas (i) é **caixa-preta** — a arquitetura empilhada não revela “quanto a fila pesa” ou “quanto um erro custa”; (ii) é **retreinado quase diariamente**, o que o torna caro, não-determinístico e difícil de auditar; e (iii) valida-se em um único ponto por dia, uma medida ruidosa de qualidade. Isso motiva buscar um modelo *fixo, rápido e interpretável* que iguale seu desempenho.

4 Seleção experimental de um modelo substituto

O objetivo do experimento (notebooks `experimento_qtd.ipynb` e `experimento_valor.ipynb`) é substituir o TPOT por um modelo confiável e rápido, comparando dezenas de candidatos sob um protocolo de avaliação honesto e idêntico para todos.

Protocolo *walk-forward* alinhado ao histórico. Cada candidato é avaliado com `TimeSeriesSplit(test_size=1, max_train_size=JANELA)` — um *fold* por dia do *backup*, retreinando na janela anterior e prevendo o próximo dia, sem jamais ver o futuro. A janela de datas é ancorada na *data mínima do backup*, para cobrir todo o período e comparar *maçã-com-maçã* com a **Pipeline Antiga** (as previsões que o TPOT realmente fez em produção). Todos os candidatos usam as *features* da Seção 3, exceto os modelos de série temporal, que aprendem a dinâmica diretamente.

Famílias de candidatos. O experimento é organizado em partes:

- **Parte 1 — modelos simples:** regressores com hiperparâmetros padrão (lineares, árvores, *gradient boosting*), um ponto de teste por dia.
- **Parte 2 — abordagens avançadas:** reproduzem, de forma transparente, o que o TPOT faz — seleção de variáveis (`SelectKBest`), *tuning* (`RandomizedSearchCV`), *ensembles* (`Voting/Stacking`) e *pipelines* com pré-processamento.

- **Parte 3 — *deep learning* e séries temporais:** LSTM, CNN 1D e *Transformer*; e modelos com dependência temporal explícita — **Auto-ARIMA**, **Prophet** e **NeuralProphet**. Também se avaliam **retrospectivamente** os próprios *pipelines* TPOT de produção (cada .pkl) nos mesmos *folds*.

Construção da base — modelos de *machine learning* (Partes 1 e 2) vs. séries temporais (Parte 3). As Partes 1 e 2 são **tabulares**: reaproveitam exatamente a mesma base de *features* da Seção 3 (`dia_semana + lag_0..6`, mais `lag_7` da fila no caso do valor) — ou seja, a dinâmica temporal é *achatada* em colunas de defasagem e o problema vira uma regressão *i.i.d.* padrão ($X \rightarrow y$), sem qualquer noção de data para o estimador. Já a Parte 3 trata a dependência temporal de forma **nativa**: os modelos sequenciais (LSTM, CNN 1D, *Transformer*) recebem as mesmas seis defasagens, mas reordenadas cronologicamente em uma *sequência* `SEQ_COLS = (lag_6, ..., lag_1)` — do dia mais antigo ao mais recente — concatenada a um vetor de contexto `CTX_COLS = (dia_semana, lag_0)`; e os modelos puramente temporais (Auto-ARIMA, Prophet, NeuralProphet) dispensam as defasagens por completo, recebendo apenas a **série bruta** e o `dia_semana` como regressor de calendário, aprendendo a autocorrelação diretamente da sequência (como fará depois o SARIMA, Seção 5). Em todos os casos, o particionamento treino/teste segue `TimeSeriesSplit(n_splits=20, test_size=1, max_train_size=JANELA_DIAS=45)`: a cada *fold* o modelo é reestimado do zero na janela de 45 dias úteis imediatamente anteriores e avaliado em **1 dia** à frente, nunca visto no treino — o mesmo protocolo *walk-forward* de um passo usado depois para o SARIMA, o que torna a comparação final maçã-com-maçã.

Algumas pipelines testadas (Parte 2, seleção TPOT-like). A Tabela 2 lista uma amostra dos candidatos pré-selecionados — pipelines com pré-processamento + *ensemble*, no mesmo estilo do que o TPOT de produção monta sozinho —, com as métricas do mesmo *walk-forward*. Os nomes seguem a notação compacta de `_pipeline_sigla (experimento_{qtd,valor}.ipynb)`: cada etapa do `sklearn.Pipeline` vira uma sigla de 2–4 letras separada por “+” (ordem = ordem de execução), e `SE(...)` indica um `StackingEstimator` — a predição de um regressor auxiliar é anexada como *feature* extra antes do passo seguinte.

Tabela 2: Amostra de pipelines pré-selecionadas (métricas do *walk-forward*, mesma base de datas do *ranking* final). Legenda das siglas: SE = `StackingEstimator`, ABR = `AdaBoostRegressor`, SPct = `SelectPercentile`, ETR/EXT = `ExtraTreesRegressor`, MMS = `MinMaxScaler`, MAS = `MaxAbsScaler`, OHE = `OneHotEncoder`, BIN = `Binarizer`, GBR/XGB/RFR = membros do *Voting* (*Gradient Boosting/XGBoost/Random Forest*); siglas sem entrada nesta lista (ex. LINE, SGDR, ELAS, LSVR) são as 4 primeiras letras do nome da classe *scikit-learn* (ex. `SGDRegressor`→SGDR).

	Pipeline	MAPE (%)	RMSPE (%)	R^2
Qtd.	SE(LINE)+SE(SGDR)+ABR	7,41	9,49	0,345
	SPct+ABR	7,47	9,59	0,336
	SE(ABR)+MAS+OHE+ABR	7,32	9,62	0,328
	SE(ETR)+MMS+BIN+SE(ELAS)+ABR	7,67	9,73	0,311
	SARIMA (univariado)	7,35	9,78	0,321
	Pipeline Antiga em Produção (TPOT)	7,89	9,88	0,313
Valor	SARIMA (univariado)	7,31	9,56	0,753
	ExtraTrees(EXT,j90)	7,47	9,94	0,718
	MAS+OHE+MAS+OHE+SE(SGDR)+MMS+LSVR	8,51	10,58	0,672
	Pipeline Antiga em Produção (TPOT)	8,48	10,75	0,696
	VotingRegressor (RF+ET+XGB)	8,19	10,77	0,673
	Voting(GBR+XGB+RFR)	8,13	10,78	0,675

Note-se que o **SARIMA** — que sequer usa a base tabular de *lags*, apenas a série bruta e os

regressores de intervenção — é o 1º colocado no valor e, na quantidade, empata em MAPE com o melhor *stacking* (7,35 vs. 7,32) ficando 0,3 p.p. atrás em RMSPE, sempre à frente da pipeline de produção. Isso reforça a conclusão da Seção 4: a sofisticação tabular (*stacking*, seleção de variáveis, *ensembles*) não compra precisão extra consistente frente a um modelo que representa a autocorrelação diretamente.

Exclusão de dias atípicos na avaliação. Há uma distinção importante entre *estimar* e *avaliar*: os dias atípicos podem entrar no treino (no SARIMA, via intervenção), mas são **removidos do ranking**. Manter um dia de falha operacional na comparação penalizaria (ou premiaria) os modelos por ruído operacional, não por capacidade preditiva, distorcendo o MAPE/RMSPE. A remoção (`mask_dias_excluir`) segue três critérios: (i) **Log de Erro** — o dia do incidente e os $n - 1$ dias úteis seguintes (coluna *impacto*, pois a fila represada “vaza” para os dias seguintes); (ii) **véspera de feriado** (Natal, Ano-Novo, Carnaval e o dia anterior); (iii) **outliers manuais** pontuais. A comparação usa as previsões *cruas* (sem correção de viés), sobre a mesma base comum de datas.

Critério de seleção — por que RMSPE. O *ranking* é ordenado por **RMSPE**, porque ele decompõe o erro em viés e dispersão:

$$\text{RMSPE} = \sqrt{\frac{1}{N} \sum_{t=1}^N \left(\frac{y_t - \hat{y}_t}{y_t} \right)^2}, \quad \underbrace{\text{RMSPE}^2}_{\text{erro total}} = \underbrace{\text{Viés}^2}_{\text{descentramento}} + \underbrace{\text{Dispersão}^2}_{\text{espalhamento}}. \quad (1)$$

Se o erro percentual fosse igual todo dia (dispersão = 0), teríamos $\text{RMSPE} = \text{MAPE}$; quanto maior a dispersão, mais o RMSPE se afasta do MAPE. Exemplo: para APes (0, 0, 6, 6), $\text{MAPE} = 3$ e dispersão = 3, logo $\text{RMSPE} = \sqrt{9 + 9} = 4,24\%$. Assim o RMSPE **penaliza outliers** mais que o MAPE e captura o *trade-off viés × variância*. As demais métricas completam o retrato: MAPE (erro típico), R^2 , Viés/MPE (erro sistemático), DP Erro, Máx.% (pior dia) e as frações de dias com erro < 5% / < 10%. Meta: $\text{MAPE} \leq 5\%$ (ideal), $\leq 10\%$ (aceitável).

Do experimento à modelagem SARIMA. O experimento mostrou que *nenhum* enriquecimento de *features* ou família de ML supera de forma consistente e interpretável os modelos de **série temporal clássica**: entre os candidatos que *igualam ou batem* a Pipeline Antiga, o **SARIMA** é o mais parcimonioso e o único totalmente auditável. Ele é, portanto, promovido de *benchmark* a **modelo recomendado** — e o restante do relatório o identifica, trata seus dias atípicos por intervenção e o estima e valida em detalhe.

5 Modelagem SARIMA: especificação, identificação e intervenção

5.1 O modelo SARIMA/SARIMAX

Seja B o operador de defasagem ($B^k y_t = y_{t-k}$). Um modelo $\text{SARIMA}(p, d, q)(P, D, Q)_s$ com regressores exógenos (SARIMAX) escreve-se como uma **regressão com erros SARIMA**:

$$y_t = \beta' \mathbf{X}_t + \eta_t, \quad \phi(B) \Phi(B^s) (1 - B)^d (1 - B^s)^D \eta_t = \theta(B) \Theta(B^s) \varepsilon_t, \quad (2)$$

onde $\mathbf{X}_t$ reúne os regressores de intervenção (Seção 5.3), $\varepsilon_t \sim \text{RB}(0, \sigma^2)$, e $\phi, \theta, \Phi, \Theta$ são, respectivamente, os polinômios autorregressivo e de média móvel não-sazonais e sazonais. Nesta aplicação $s = 5$ e, como se verá, $d = 1$, $D = 0$. Os dois modelos escolhidos são **SARIMA univariados** (não usam covariável de negócio): os únicos regressores em $\mathbf{X}_t$ são as *dummies* de intervenção.

5.2 Identificação: estacionariedade e ordem

A identificação segue Box–Jenkins: (i) **estacionariedade** por ADF e KPSS; (ii) inspeção de **ACF/PACF** em nível e na primeira diferença; (iii) **decomposição STL** (período 5) para separar tendência, sazonal e resíduo. A ordem $(p, d, q)(P, D, Q)_5$ é escolhida por **auto_arima** (busca *stepwise* minimizando o AIC), *uma única vez*, sobre a série inteira — um vazamento *leve e restrito à especificação*; os **coeficientes**, porém, são reestimados honestamente a cada dia do *walk-forward* (MLE via filtro de Kalman, só com o passado — Seção 4).

5.3 Análise de intervenção (Box–Tiao)

Dias atípicos — incidentes operacionais registrados no **Log_Erro** e vésperas de Natal/Ano-Novo/Carnaval — produzem *spikes* que, se ignorados, contaminam a estimação de $\phi, \theta, \Phi, \Theta$. Em vez de descartar esses dias da estimação, adota-se o **modelo de intervenção de Box–Tiao**: cada evento entra como um regressor determinístico cuja resposta dinâmica é uma *função de transferência* aplicada a um indicador de pulso

$$P_t = 1\{t \in \mathcal{D}_E\}, \quad y_t = \frac{\omega(B)}{\delta(B)} B^b P_t + N_t, \quad (3)$$

onde $\mathcal{D}_E$ é o conjunto de datas do evento E , N_t é o ruído SARIMA de (2), e $\frac{\omega(B)}{\delta(B)} B^b$ controla magnitude, atraso (b) e persistência do efeito. Teoricamente, erros operacionais são *impulsos* (não deixam impacto permanente na série). As formas funcionais testadas por evento são casos particulares de (3), resumidas na Tabela 3.

Tabela 3: Famílias de função de intervenção testadas. O fator $\delta \in (0, 1)$ controla a velocidade do decaimento; $d_0 < \dots < d_{n-1}$ são os dias úteis afetados por um evento de duração n . A forma vencedora de cada evento é a de coeficiente(s) significativo(s) ($p < 0,05$) e menor AIC; sem nenhum significativo $\rightarrow$ “não signif.”; empate $\rightarrow$ a mais simples.

Forma	Regressor	Interpretação
Abrupto	$x_t = P_t$	choque constante nos dias de impacto, retorno abrupto a zero
Gradual	$x_t = \frac{n-k}{n}, t = d_k$	rampa linear decrescente (1 no 1º dia $\rightarrow 1/n$ no último)
Rebote (2 reg.)	$x_t^{(1)} = 1\{t = d_0\}, x_t^{(2)} = 1\{t \in \{d_1, \dots\}\}$	queda no 1º dia + recuperação (sinais opostos) do <i>backlog</i>
Transf. g	$x_t = \delta x_{t-1} + P_t$	choque temporário com decaimento geométrico
Transf. b	$x_t = \delta x_{t-1} + P_{t-1}$	igual ao g , com atraso de um dia
Transf. c	$x_t = \sum_{\tau \leq t} P_\tau$	degrau permanente (mudança de patamar)
Transf. e (2)	$x_t^{(1)} = P_t, x_t^{(2)} = \delta x_{t-1} + P_t$	pulso imediato + cauda que decai
Transf. d (2)	$x_t^{(1)} = \delta x_{t-1}^{(1)} + P_t, x_t^{(2)} = \sum_{\tau \leq t} P_\tau$	transitório que decai + degrau permanente
Transf. f	$x_t = \sum_{\tau \leq t} v_\tau, v_\tau = \delta v_{\tau-1} + P_\tau$	convergência suave a um novo patamar

Cada **tipo** de dia atípico é classificado de forma *independente* por série: as vésperas de feriado são separadas em “dia anterior à véspera” (D-1) e “véspera” propriamente, e cada uma — assim como cada incidente do **Log_Erro** — pode receber uma forma diferente no valor e na quantidade.

A intervenção **mantém** os dias especiais no treino (necessário para estimar o efeito), mas nos dias de avaliação (normais) as *dummies* valem zero. Assim, os coeficientes AR/MA descrevem a *dinâmica normal* da série, e cada choque atípico recebe um coeficiente e um *p*-valor próprios — exatamente o que a caixa-preta não oferece.

5.4 Cointegração

Como valor e quantidade parecem “andar juntas”, testa-se se há **equilíbrio de longo prazo** entre elas. Se forem cointegradas com vetor $(1, -\beta)$, o *ticket médio* (valor/qtd) seria estacionário. Aplicam-se **Engle–Granger** e **Johansen** (traço) sobre os níveis, com seleção prévia do *lag* do VAR por critério de informação, mais o ADF do *ticket médio* e o ADF com tendência (ct) para descartar *trend-stationarity*. Antes dos testes, remove-se dos níveis o efeito de *pulso* dos dias atípicos. O teste decide se as séries devem ser modeladas *juntas* (VECM/ARDL) ou *separadamente*.

6 Resultados

6.1 Identificação e estacionariedade

A ACF em nível decai lentamente nas duas séries (não-estacionariedade), justificando $d = 1$; na primeira diferença surge um pico negativo no *lag* 1 — assinatura de **MA(1)** (Figura 2). A **decomposição STL** (período 5) confirma o padrão nas duas séries (Figuras 3 e 4): **tendência** suave de médio prazo, **sazonalidade semanal** clara e **resíduo** com *spikes* concentrados nos dias atípicos (que a intervenção trata). A ordem selecionada foi SARIMA(0, 1, 1)(0, 0, 1)₅ para o valor e (0, 1, 1)(0, 0, 2)₅ para a quantidade.




Figura 2: ACF/PACF do valor: nível decai lentamente ($I(1)$); a 1ª diferença apresenta corte no *lag* 1, sugerindo MA(1). Padrão análogo na quantidade.



Figura 3: Decomposição STL (período 5) da série de **valor**: observado, tendência, sazonal semanal e resíduo. A tendência sobe ao longo de 2025–2026; o resíduo concentra os *spikes* nos dias atípicos.




Figura 4: Decomposição STL (período 5) da série de **quantidade**: mesmo padrão (tendência + sazonal semanal + resíduo com *spikes*), com histórico ligeiramente mais curto.

6.2 Cointegração: não há equilíbrio de longo prazo

Após remover o pulso dos dias atípicos, Engle–Granger **não rejeita** a ausência de cointegração (estatística = $-1,02$, $p = 0,900$) e o ADF do *ticket* médio indica erro de equilíbrio não-estacionário ($p = 0,631$; com tendência, $p = 0,383$) — Tabela 4. O Johansen sem tendência aponta 0 relações (traço $12,84 < 15,49$ a 5%); com tendência determinística aponta 2, mas isso

coincide com a *trend-stationarity* detectada pelo ADF-ct, ou seja, *não* é cointegração genuína. A relação estimada foi valor = $-1.830.731 + 2.332,69 \cdot \text{qtd}$ ($\beta \approx \text{ticket}$ médio), mas seu resíduo **deriva** ao longo do tempo (Figura 5).

Tabela 4: Testes de raiz unitária e cointegração (níveis ajustados para intervenção).

Teste	Valor	Quantidade	Leitura
ADF nível	$p = 0,723$	$p = 0,0005$	valor $I(1)$ û qtd $I(0)$ (ordens mistas)
ADF 1ª dif.	$p = 0,000$	$p = 0,000$	ambas estacionárias diferenciadas
ADF-ct	$p = 0,0005$	$p = 0,0002$	ambas <i>trend-stationary</i>
Engle-Granger (-1,02)	$p = 0,900$		não rejeita → sem cointegração
ADF do <i>ticket</i> médio	$p = 0,631$		erro de equilíbrio não-estacionário
ARDL <i>bounds</i> (caso III)	$F = 2,36$	$F = 2,66$	$F < I(0)_{5\%} = 3,80 \rightarrow$ não rejeita




Figura 5: Superior: valor e quantidade padronizados (z-score), dias atípicos ajustados em vermelho. Inferior: resíduo de Engle-Granger — **deriva** em vez de oscilar em torno de zero, evidência visual da ausência de cointegração.

Follow-up formal (ARDL). Como as ordens de integração são **mistas** $I(0)/I(1)$, o teste apropriado dispensa a pré-classificação em $I(1)$: o **teste de limites** de Pesaran-Shin-Smith (*bounds test*), que verifica a existência de uma *relação de nível*. Nas duas direções a estatística F (2,36 para valor|qtd, ARDL(3,3); 2,66 para qtd|valor, ARDL(4,4)) fica **abaixo do limite inferior** $I(0)$ a 5% (3,80) — *não* se rejeita a ausência de relação de nível, **confirmando** Engle-Granger e Johansen (Tabela 4).

Por que a rejeição faz sentido, e como (não) modelar as séries juntas

À primeira vista valor e quantidade “andam juntas” e a tentação é modelá-las conjuntamente. O ponto é que **co-movimento contemporâneo** $\neq$ **cointegração**. Cointegração descreve um *equilíbrio de longo prazo*: um desvio entre as séries hoje é *corrigido ao longo dos dias* (mecanismo de correção de erro) — um fenômeno *defasado*. A relação valor-quantidade, porém, é quase a identidade contábil *contemporânea* $\text{valor}_t \approx \bar{t}_t \cdot \text{qtd}_t$ (com $\bar{t} = \text{ticket}$ médio do dia): mais propostas hoje → mais valor *hoje*, no mesmo dia, sem desequilíbrio que leve dias para se dissipar. Somando-se a isso que o ADF-ct aponta as séries como *trend-stationary* (próximas de $I(0)$), e que cointegração — definida apenas para séries $I(1)$ — torna-se *inaplicável*, a rejeição é o resultado **esperado**, não um fracasso: ela só descarta a família VECM/correção de erro.

Rejeitar cointegração não impede modelagem conjunta — muda apenas *qual* modelo é apropriado. Quatro alternativas foram testadas no **mesmo walk-forward 1-passo e nas mesmas datas** do *ranking* univariado (contraste controlado, todas sem *dummies* de intervenção):

1. **(a) Decomposição por ticket** — valor = qtd $\times$ ticket: prevê-se qtd e *ticket* (= valor/qtd) por SARIMA e recompõe-se $\hat{v} = \hat{q} \cdot \hat{t}$. Usa a identidade estrutural, mas *exige prever qtd primeiro* (sistema encadeado); só se aplica ao valor.
2. **(b) SUR bivariado** — duas equações com regressores próprios defasados + *dummies* de dia-da-semana, estimadas em conjunto (FGLS de Zellner) com erros correlacionados.
3. **(c) VAR em diferenças** — o modelo conjunto *clássico quando não há cointegração* (VAR nas 1^{as} diferenças, não VECM), com *dummies* semanais como exógenas.
4. **(d) ARDL encadeado** — regressão ARDL de uma série sobre *lags* da outra, com o termo contemporâneo substituído pela previsão univariada da outra série (sem vazamento); a contraparte *preditiva* do teste de limites ARDL acima.

Adicionalmente, a mesma bateria testa se **outra especificação univariada** bate o SARIMA na própria frente onde ele já joga (sem qualquer ligação entre as séries):

- (e) **(e) Prophet** — decomposição aditiva tendência + sazonalidade semanal, otimização bayesiana (Stan); robusto a *outliers*, dispensa escolha manual de ordem.
- (f) **(f) UCM** (*Unobserved Components*) — modelo estrutural de espaço de estados (*local linear trend* + sazonal estocástico, período 5): decompõe nível, inclinação e sazonalidade como componentes latentes filtrados por Kalman, em vez do MA/AR do SARIMA sobre a diferença.
- (g) **(g) TVP-regressão** (parâmetros variantes no tempo) — intercepto, *dummies* de dia-da-semana e lag₁, mas com **coeficientes em passeio aleatório** (filtro de Kalman) em vez de fixos.

A Tabela 5 traz o resultado completo. **O SARIMA univariado é o mais adequado.** Na quantidade ele vence na frente (RMSPE 9,07% contra 9,24% do ARDL, 9,42% do UCM, 9,47% do TVP, 9,48% do VAR e 10,80% do SUR); Prophet fica ainda mais atrás (10,58%). No valor, *ticket* e *ARDL encadeado* apenas *empatam* (9,46% e 9,54% vs. 9,55%, $\leq 0,1$ p.p., dentro do ruído amostral) — e nem são modelos de dinâmica conjunta: usam a identidade estrutural e ainda precisam prever a quantidade antes ($\hat{q}$). TVP já perde por $\approx 0,4$ p.p. (9,95%); **SUR, Prophet e UCM pioram** de forma acentuada (12,14%, 12,89% e 16,03%). O motivo, para SUR/VAR, confirma a leitura da cointegração: o elo forte é *contemporâneo* e, portanto, *inutilizável* para prever D+1 (não se conhece o qtd de amanhã ao prever o valor); resta o elo *defasado*, fraco, cujos termos cruzados só adicionam **variância** sem reduzir viés. Já Prophet e UCM perdem por razão diferente: são **mais parametrizados** que o SARIMA parcimonioso (0, 1, 1)(0, 0, q)₅ e, com um treino curto no início de cada janela ($\sim 25\text{--}35$ obs.), pagam essa flexibilidade extra em variância sem reduzir viés — o padrão real é simples (MA(1) sobre a diferença + sazonalidade semanal fraca) e não recompensa componentes latentes extras. O TVP fica perto por razão semelhante, mas o efeito é pequeno porque a variação real dos coeficientes ao longo da amostra é modesta.

Tabela 5: Modelagem conjunta e especificações univariadas alternativas vs. SARIMA univariado — walk-forward 1-passo, mesmas janelas (sem intervenção). Menor RMSPE por série em negrito.

Série	Modelo	RMSPE (%)	MAPE (%)	R^2
Valor ($N=259$)	(a) Ticket $\hat{q} \cdot \hat{t}$	9,46	7,58	0,755
	(d) ARDL valor $\leftarrow$ qtd	9,54	7,57	0,752
	SARIMA univariado	9,55	7,70	0,743
	(g) TVP-regressão	9,95	7,81	0,725
	(c) VAR em diferenças	9,99	7,80	0,719
	(b) SUR bivariado	12,14	9,55	0,567
	(e) Prophet	12,89	9,90	0,604
	(f) UCM	16,03	11,83	0,228
Qtd. ($N=211$)	SARIMA univariado	9,07	7,32	0,399
	(d) ARDL qtd $\leftarrow$ valor	9,24	7,56	0,372
	(f) UCM	9,42	7,56	0,356
	(g) TVP-regressão	9,47	7,35	0,351
	(c) VAR em diferenças	9,48	7,30	0,336
	(e) Prophet	10,58	8,54	0,205
	(b) SUR bivariado	10,80	8,62	0,102

Consequência metodológica: como o erro de equilíbrio não reverte à média, o teste de limites ARDL *não rejeita* a ausência de relação de nível e *nenhuma* alternativa — conjunta (b/c/d) ou univariada mais flexível (e/f/g) — supera o univariado, *modelam-se as séries separadamente* com o SARIMA parcimonioso (+ intervenção). As alternativas conjuntas ou empatam (*ticket*/ARDL, estruturais e encadeados) ou pioram (SUR/VAR); as univariadas mais parametrizadas (Prophet, UCM, TVP) pagam variância extra sem reduzir viés, num padrão que já é simples. O *follow-up* formal apropriado ao caráter misto $I(0)/I(1)$ é justamente o ARDL (Pesaran–Shin–Smith), não o VECM — e foi ele que fechou o argumento.

6.3 Intervenção: classificação por evento e descontaminação do ajuste

No modelo congelado de produção, **23 janelas de evento** foram classificadas em cada série — os 17 incidentes operacionais do Log_Erro mais 6 janelas de véspera de feriado (o “dia anterior” D-1 e a “véspera”, para Natal, Ano-Novo e Carnaval). A escolha da forma vencedora é feita *por série de forma independente*; a Tabela 6 resume a distribuição das formas, a Figura 6 traz a **magnitude do efeito** evento a evento, e a Figura 7 mostra os **eventos ao longo do tempo** sobre as séries.

Tabela 6: Distribuição das formas de intervenção escolhidas (função vencedora por AIC), por série — fonte: `config/modelo_sarima_producao.json`. As 23 janelas incluem os 17 incidentes do `Log_Erro` e 6 janelas de véspera. Fórmulas conforme a Eq. (3) e a Tabela 3 (P_t : pulso do evento; $\delta \in (0, 1)$: decaimento; $d_0, \dots, d_{n-1}$: dias do evento).

Forma de intervenção	Fórmula	Valor (n)	Quantidade (n)
Abrupto (choque pontual)	$x_t = P_t$	5	3
Gradual (rampa decrescente)	$x_t = \frac{n-k}{n}, t = d_k$	5	0
Rebote (queda + recuperação)	$x_t^{(1)} = 1\{t = d_0\}, x_t^{(2)} = 1\{t \in \{d_1, \dots\}\}$	2	0
b (geom. com atraso 1 dia)	$x_t = \delta x_{t-1} + P_{t-1}$	3	5
c (degrau permanente)	$x_t = \sum_{\tau \leq t} P_\tau$	0	3
e (pulso + cauda)	$x_t^{(1)} = P_t, x_t^{(2)} = \delta x_{t-1}^{(2)} + P_t$	2	2
f (patamar suave)	$x_t = \sum_{\tau \leq t} v_\tau, v_\tau = \delta v_{\tau-1} + P_\tau$	0	3
g (decaimento geométrico)	$x_t = \delta x_{t-1} + P_t$	1	1
Não signif. (descartado)	—	5	6
Total		23	23

Dois padrões chamam a atenção. Primeiro, **o mesmo evento raramente recebe a mesma forma nas duas séries**: são 6/23 janelas “não signif.” na quantidade e 5/23 no valor, e as classes vencedoras quase nunca coincidem — uma parada operacional pode mudar o *quanto* é processado sem mudar *quantas* propostas entram (e vice-versa). Segundo, o *perfil* do efeito difere por série: na **quantidade** predominam formas com **cauda/persistência** (b, c, e, f : 11 das 17 janelas significativas) — o *backlog* é processado nos dias seguintes —, enquanto no **valor** dominam choques pontuais e rampas (abrupto/gradual/rebote: 12/18). As vésperas seguem padrão próprio e *idêntico* nas duas séries: o dia anterior (D-1) é um pulso com cauda ($e, \delta = 0,1$) e a véspera de Natal e de Ano-Novo é um choque **abrupto**; o Carnaval não é significativo em nenhuma das duas.




Figura 6: Magnitude do efeito estimado (coeficiente principal da função vencedora) por evento, para o **valor** (topo) e a **quantidade** (base); a cor indica a forma de intervenção vencedora. Os efeitos são predominantemente negativos (paradas derrubam a série); as vésperas de Natal/Ano-Novo têm forte componente de cauda (função *e*), e vários incidentes que pesam no valor são *não signif.* na quantidade.




Figura 7: Eventos de intervenção ao longo do histórico, sobre as séries de valor (topo) e quantidade (base). Cada ponto marca um dia de evento, colorido pela **função vencedora** (mesmo código da Figura 6); os pontos cinza (“não signif.”) foram testados e descartados. Fonte: modelo congelado de produção.

O efeito da intervenção sobre a *qualidade do ajuste* é um dos resultados centrais: com as *dummies*, o **Ljung-Box deixa de rejeitar** a hipótese de resíduos não-autocorrelacionados — o $p(10)$ sobe de $\approx 0,01$ (sem intervenção, em ambas as séries) para **0,32** (valor) e **0,99** (quantidade); no *lag* 20, onde a rejeição era ainda mais clara ($p < 0,01$), passa a 0,25/0,99 — como mostra a Tabela 7. Isso fica visual de duas formas. (i) **No tempo**: o resíduo *pré* intervenção tem *spikes* enormes exatamente nos dias de *Log_Erro* e véspera (linhas marcadas); *pós* intervenção esses picos desaparecem e o resíduo fica homogêneo (Figuras 8 e 9). (ii) **Na distribuição**: no *plot_diagnostics* (Figuras 10 e 11), antes da intervenção o **Q-Q** exibe uma cauda inferior pesada e o **histograma** é leptocúrtico; depois, os resíduos se aproximam nitidamente da normal. Persistem, como ressalva, **heterocedasticidade** e **caudas pesadas** residuais (Jarque-Bera significativo) — erros maiores nos dias atípicos —, o que torna os intervalos de confiança otimistas nos extremos.




Figura 8: Resíduo do SARIMA de **valor** ao longo do tempo, *pré* (topo, com os dias de *Log_Erro* e *véspera* marcados) vs. *pós* intervenção (base). Os *spikes* nos dias atípicos somem após o tratamento.




Figura 9: Resíduo do SARIMA de **quantidade** ao longo do tempo, *pré* vs. *pós* intervenção. Mesmo efeito: os picos dos dias atípicos são absorvidos.

Valor (R\$): distribuição dos resíduos — pré vs. pós intervenção




Figura 10: Distribuição dos resíduos do SARIMA de **valor** — histograma (topo) e Q-Q normal (base), *pré* (esquerda) vs. *pós* (direita) intervenção. A cauda inferior pesada do Q-Q (dias de erro puxando os resíduos) some após a intervenção, e o histograma se aproxima da $N(0,1)$.

Quantidade de propostas: distribuição dos resíduos — pré vs. pós intervenção




Figura 11: Distribuição dos resíduos do SARIMA de **quantidade** — histograma (topo) e Q-Q normal (base), *pré* vs. *pós* intervenção. Mesmo padrão: os resíduos se aproximam da normal após tratar os dias atípicos.

6.4 Estimação: coeficientes e significância

A Tabela 7 traz o ajuste *in-sample* do modelo congelado (regressão com erros SARIMA + intervenção, $N = 409$). O achado central é econométrico: o **motor preditivo é a MA(1)**, não a sazonalidade. O termo $\theta_1 \approx -0,6$ é grande e altamente significativo ($p < 0,001$) nas duas séries — de longe o coeficiente mais forte. Num IMA(1,1), isso equivale a uma **suavização do tipo média móvel exponencial**: a previsão de amanhã é o nível de hoje corrigido por $\approx 60\%$ do erro de previsão de ontem. A **sazonalidade semanal é real, mas fraca** (Θ pequenos e não significativos individualmente, $p \geq 0,10$): a maior parte do padrão semanal já é absorvida pela diferenciação e pela grade de dias úteis.

Tabela 7: Coeficientes *in-sample* do modelo congelado ($N = 409$ dias úteis) e diagnóstico de Ljung-Box. Fonte: reestimação do *config* congelado (*config/modelo_sarima_producao.json*) sobre o histórico atual.

Termo	Valor (0, 1, 1)(0, 0, 1) ₅	Qtd (0, 1, 1)(0, 0, 2) ₅
MA(1) — θ_1 (choque de ontem)	−0,646 ũ $p < 0,001$	−0,617 ũ $p < 0,001$
MA sazonal — Θ_1 (lag 5)	−0,078 ũ $p = 0,10$	−0,035 ũ $p = 0,48$
MA sazonal — Θ_2 (lag 10)	—	+0,022 ũ $p = 0,68$
AIC (sem → com intervenção)	11.804,8 → 11.648,0	5.728,5 → 5.596,5
Ljung-Box $p(10)$ (com interv.)	0,32 ✓	0,99 ✓
Ljung-Box $p(10)$ (sem interv.)	$\approx 0,01$ ✗	$\approx 0,01$ ✗
Ljung-Box $p(20)$ (sem → com)	$< 0,01 \rightarrow 0,25$	$< 0,01 \rightarrow 0,99$

6.5 *Ranking* diário — histórico completo

Sob o mesmo protocolo *walk-forward*, o SARIMA compete com a pipeline antiga e com os melhores modelos de ML/TPOT. Os resultados diferem entre as séries e merecem leitura cuidadosa.

Valor (Tabela 8). O SARIMA é o **1º colocado**: melhor RMSPE (9,56%), melhor MAPE (7,31%), melhor R^2 (0,753) e menor viés (+31.445 vs. +46.274 da antiga — MPE de apenas 0,05%). O ExtraTrees ganha somente na fração de dias com erro < 10% (199 vs. 193 de 259). É uma vitória limpa nas quatro métricas principais.

Tabela 8: *Ranking* — Valor (histórico completo, $N = 259$, ordenado por RMSPE). Viés em R\$.

Modelo	MAPE%	RMSPE%	R^2	Viés	Máx.%	<10%
SARIMA	7,31	9,56	0,753	+31.445	39,85	193/259
ExtraTrees (EXT, j90)	7,47	9,94	0,718	+94.315	42,56	199/259
MAS+OHE+...+SE(SGDR)+MMS+LSVR	8,51	10,58	0,672	+78.391	32,06	169/259
Pipeline Antiga em Produção	8,48	10,75	0,696	+46.274	41,02	168/260
Voting (GBR+XGB+RFR)	8,13	10,78	0,675	+135.933	33,35	180/259

Quantidade (Tabela 9). Aqui a leitura é *mista* e o relatório é honesto quanto a isso. O SARIMA tem o **menor viés (26,3)** — centradíssimo —, MAPE praticamente empatado com o melhor ML (7,35% vs. 7,32%) e 95/211 dias com erro < 5% (vs. 96 do melhor). Porém, no critério de *ranking* (RMSPE) fica atrás dos melhores *stackings* (9,78% vs. 9,49%) e tem o **pior erro máximo (50,83%)**: um único dia muito ruim (justamente o que o RMSPE penaliza). Ou seja, o SARIMA é o *mais bem centrado*, mas não o de menor dispersão de cauda na quantidade — ainda assim supera a pipeline antiga em RMSPE (9,78 vs. 9,88) e em MAPE.

Tabela 9: *Ranking* — Quantidade (histórico completo, $N = 211$, ordenado por RMSPE).

Modelo	MAPE%	RMSPE%	R^2	Viés	Máx.%	<5%
SE(LINE)+SE(SGDR)+ABR	7,41	9,49	0,345	59,6	31,26	88
SPct+ABR	7,47	9,59	0,336	61,0	31,26	85
SE(ABR)+MAS+OHE+ABR	7,32	9,62	0,328	43,7	34,42	96
SE(ETR)+MMS+BIN+SE(ELAS)+ABR	7,67	9,73	0,311	69,9	29,60	85
SARIMA	7,35	9,78	0,321	26,3	50,83	95
Pipeline Antiga em Produção	7,89	9,88	0,313	40,5	34,06	87

No **recorte recente (janeiro em diante)** a vantagem dos modelos brancos cresce e fica mais estável. O acompanhamento do previsto $\times$ realizado (Figura 12) mostra que o SARIMA segue bem nível e sazonalidade, com os maiores erros nos saltos pós-atípicos — onde a pipeline antiga também erra.




Figura 12: Valor previsto (SARIMAX, variante com a fila D−1) × realizado × pipeline antiga ao longo do período de avaliação. Os maiores erros concentram-se nos saltos pós-atípicos.

6.6 Modelos mensais: *nowcast* e comparação

Como extensão, estuda-se a previsão do **total do mês**. O *nowcast* soma o realizado acumulado até o dia D à previsão SARIMA dos dias úteis restantes: $\text{Nowcast}(D) = \text{acumulado}(\leq D) + \text{restante}$; conforme o mês avança, mais dias viram realizado e a estimativa converge (Figura 13). Agregando os 19 meses completos, o $|\text{Erro } \%|$ mediano começa em $\approx 5\text{--}7\%$ e cai para $< 2\%$ a partir de $\approx 2/3$ do mês.

Comparando abordagens de total mensal (Tabelas 10 e 11), **um resultado honesto se impõe**: para o total mensal, a *persistência* ingênua (**Naive**, repetir o mês anterior) é a melhor, e o modelo paramétrico direto (ARIMAX) é o *pior*. O *nowcast* fica em posição intermediária — útil por atualizar em tempo real ao longo do mês, mas não a melhor previsão *a priori* do total.

Tabela 10: Total mensal — **Valor**. Ordenado por RMSPE. (Viés em R\$.)

Modelo	MAPE%	RMSPE%	Mediana%	Máx.%	R^2
Naive (mês−1)	3,53	4,66	2,33	9,50	0,641
Nowcast (últ. dia mês−1)	4,43	5,27	4,17	11,04	0,547
MediaUtil MM3	6,17	6,92	5,29	11,80	0,280
ARIMAX	7,70	8,53	7,77	14,18	−0,078

Tabela 11: Total mensal — **Quantidade**. Ordenado por RMSPE.

Modelo	MAPE%	RMSPE%	Mediana%	Máx.%	R^2
Naive (mês−1)	2,94	3,64	2,80	6,89	0,597
MediaUtil MM3	3,27	4,06	2,77	7,19	0,519
Nowcast (últ. dia mês−1)	4,19	4,57	3,82	7,80	0,368
ARIMAX	5,49	6,55	3,65	11,17	−0,277




Figura 13: Trajetória mediana do erro percentual do *nowcast* ao longo do mês (faixa: IQR 25–75% entre meses), valor e quantidade.

7 Discussão e interpretação

Os modelos revelam, com significância estatística:

1. **As séries têm nível que passeia**, não uma média fixa ($I(1)$): a melhor âncora para amanhã é o nível de hoje, não uma média histórica.
2. **O motor é a MA(1)**, não a sazonalidade: $\theta_1 \approx -0,6$ ($p < 0,001$) domina; o padrão semanal é real mas fraco.
3. **Dias de erro têm efeito real e mensurável** — entram como *intervenção*, não como descarte. O mesmo evento raramente recebe a mesma forma nas duas séries (6/23 “não signif.” na qtd, 5/23 no valor), e na quantidade o efeito tipicamente tem cauda (*backlog*).
4. **Valor e quantidade não compartilham equilíbrio de longo prazo** — a modelagem separada é a escolha correta.

Leitura crítica. O argumento a favor do modelo branco é **forte no valor** (SARIMA 1º em RMSPE, MAPE, R^2 e viés) e **qualitativamente forte nas duas séries** (interpretabilidade, diagnóstico de Ljung–Box, especificação congelada). Deve-se ser honesto, porém, em dois pontos: (i) na **quantidade**, o SARIMA *não* é o melhor no critério de *ranking* (RMSPE 9,78% vs. 9,49% do melhor *stacking*) e tem o *pior* erro máximo (50,83%) — é o mais bem centrado (menor viés, MAPE de ponta), mas paga em um dia de cauda; (ii) o **ganho de acurácia** sobre a pipeline antiga é, no geral, *marginal*. A tese que se sustenta com robustez não é “prevê muito melhor”, e sim “**empata ou supera em acurácia e ganha em interpretabilidade, auditabilidade e tratamento explícito de choques**”, com a vantagem operacional de uma *única* especificação congelada contra o retreino diário da caixa-preta. Nos **totais mensais**, a recomendação prática é a persistência (Naive)/nowcast, não o paramétrico direto.

8 Conclusão

- **Valor** → SARIMA (0, 1, 1)(0, 0, 1)₅ + intervenção: 1º no *ranking*, melhor RMSPE (9,56%), MAPE (7,31%), R^2 (0,753) e viés quase nulo (MPE 0,05%).
- **Quantidade** → SARIMA (0, 1, 1)(0, 0, 2)₅ + intervenção: menor viés e MAPE empatado com o melhor ML (7,35% vs. 7,32%), supera a pipeline antiga em RMSPE; univariado e parcimonioso.

Responde-se afirmativamente à pergunta de pesquisa: um modelo *branco*, com especificação única congelada, **igual ou supera** a pipeline em produção nas duas séries, sem abrir mão de interpretabilidade. A análise de intervenção de Box–Tiao mostrou-se decisiva para desconaminar o ajuste (Ljung–Box de $\approx 0,01$ para 0,32/0,99) e a ausência de cointegração legitimou a modelagem separada — confirmada pelo teste de limites **ARDL** (que também não rejeita a ausência de relação de nível) e, empiricamente, pelo *walk-forward*, já que nenhuma alternativa conjunta (ticket, ARDL, SUR, VAR) nem especificação univariada mais flexível (Prophet, UCM, TVP) supera o SARIMA univariado (Tabela 5). Em uma frase: *ambas as séries são bem descritas por uma suavização MA(1) sobre a série diferenciada, com sazonalidade semanal leve e os dias atípicos tratados explicitamente por intervenção de Box–Tiao*.

Limitações e próximos passos. (i) **Heterocedasticidade e caudas pesadas** nos resíduos tornam os intervalos de confiança otimistas nos extremos — modelar a variância (**GARCH**) daria IC honestos também para os dias típicos; (ii) a modelagem *conjunta* poderia ainda ser explorada por um **modelo de fator dinâmico** ou por SUR com covariância de erro plena (útil para *intervalos conjuntos*, ainda que sem ganho de ponto esperado, dado o elo contemporâneo); (iii) validar e aprimorar os **modelos mensais** (o Naive vencer sugere reavaliar o nowcast como acompanhamento, não como previsão *a priori*); (iv) a classe da intervenção é fixada uma vez na série inteira (*look-ahead* estrutural leve, mitigado por ser majoritariamente calendário).

Referências

- Box, G. E. P.; Jenkins, G. M.; Reinsel, G. C. *Time Series Analysis: Forecasting and Control*. Wiley.
- Box, G. E. P.; Tiao, G. C. (1975). *Intervention Analysis with Applications to Economic and Environmental Problems*. JASA, 70(349), 70–79.
- Engle, R. F.; Granger, C. W. J. (1987). *Co-integration and Error Correction*. Econometrica, 55(2), 251–276.
- Johansen, S. (1991). *Estimation and Hypothesis Testing of Cointegration Vectors in Gaussian VAR Models*. Econometrica, 59(6), 1551–1580.
- Pesaran, M. H.; Shin, Y.; Smith, R. J. (2001). *Bounds Testing Approaches to the Analysis of Level Relationships*. J. Applied Econometrics, 16(3), 289–326.
- Apresentação de referência: *Projeção de Vendas — Definição de Modelo (v2)*.
- Documentação interna do projeto: docs/apresentacao_sarima_valor.md, docs/modelo_sarima_intervencoes.md, config/modelo_sarima_producao.json.